

基礎程式設計(一)-期末報告

元智大學網頁爬蟲



大一化材B班

1131116 Sunny Liu

連結: https://github.com/sunnyliuaviation/Yzu_Web_Crawler

目錄

- 研究動機
- 製作目標
- 學習方法
- 爬蟲重點
- 程式設計邏輯
- 程式碼
- 完整程式碼儲存在GitHub上
- 執行結果
- 遇到的困難及如何解決
- 學習心得
- 改善及建議
- 參考資料



研究動機

隨著訊息化時代的到來，網絡資訊的更新速度日益加快，學校及各行政單位的公告、通知和最新消息通常都會在官網上發佈。對於我身為學生而言，定期查閱學校最新的重要資訊是非常重要的。然而，由於資訊更新頻繁，若依賴手動查詢，不僅耗費大量時間與精力，也容易錯過關鍵的訊息，因此想製作一個網頁爬蟲來抓取最新消息。

製作目標



自動化

每天自動抓取元智大學首頁的公告，節省手動查詢時間。



儲存資料

將公告的標題、連結、日期儲存到 Google Sheets，以避免重複抓取。



郵件通知

發現新公告後，自動寄送通知郵件給自己。



自動化執行

透過將程式碼架設在 GitHub 上，於每日早上七點執行

學習方法



構思「需求」(我希望這個爬蟲能協助我抓取到哪些資訊，並如何整理)。

開始製作，透過網路資源，
如: YOUTUBE、
GOOGLE 等網路教學學習
來撰寫程式碼。

過程中遇到許多報錯，若
遇到無法解決的問題則向
CHATGPT 尋求協助。

爬蟲重點



抓取元智大學首頁的訊息公告。

路徑：

元智大學首頁 → 最新消息 → 公告。




將抓取下來的公告儲存到 Google Sheet 中，以便在下次抓取公告時，透過比對 URL 來確認該公告是否已經抓取。



經比對後，已抓取過的公告不再抓取；未抓取過的公告則儲存到 Google Sheet 中，並使用 Gmail 傳送到自己的信箱。

程式設計邏輯



程式碼

設定環境變數

```
import requests
from bs4 import BeautifulSoup
import smtplib
from email.mime.multipart import MIMEMultipart
from email.mime.text import MIMEText
import json
import gspread
from oauth2client.service_account import ServiceAccountCredentials

# 讀取環境變數 (從 GitHub Secrets)
sender_email = os.environ['SENDER_EMAIL']
receiver_email = os.environ['RECEIVER_EMAIL']
password = os.environ['GMAIL_PASSWORD']
spreadsheet_id = os.environ['SPREADSHEET_ID']
```

```
# 讀取存於 GitHub Secrets 中的 Google Sheets 憑證 (JSON)
credentials_json_str = os.environ['GOOGLE_CREDENTIALS_JSON']
credentials_info = json.loads(credentials_json_str)
```

Google Sheets API 認證

```
scope = ['https://spreadsheets.google.com/feeds', 'https://www.googleapis.com/auth/drive']
creds = ServiceAccountCredentials.from_json_keyfile_dict(credentials_info, scope)
client = gspread.authorize(creds)

# 開啟 Google Sheets 文件
sheet = client.open_by_key(spreadsheet_id).sheet1 # 獲取第一個工作表
```

模擬使用者發出的 HTTP GET 請求， 抓取網頁內容，並檢查回應狀態

```
# 發送 HTTP GET 請求並獲取伺服器回應
scope = ['https://spreadsheets.google.com/feeds', 'https://www.googleapis.com/auth/drive']
creds = ServiceAccountCredentials.from_json_keyfile_dict(credentials_info, scope)
client = gspread.authorize(creds)

# 開啟 Google Sheets 文件
sheet = client.open_by_key(spreadsheet_id).sheet1 # 獲取第一個工作表
```

公告儲存到 Google Sheet

```
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko)'
}

url = 'https://www.yzu.edu.tw/index.php/tw'
url_page = url[url.find('/') : url.find('/') + 2]

# 發送 HTTP GET 請求並獲取伺服器回應
response = requests.get(url, headers=headers)

if response.status_code == 200:
    soup = BeautifulSoup(response.text, 'html.parser')

    # 找到所有 class 為 'msg-content' 的 div 元素
    content_divs = soup.find_all('div', class_='msg-content')
```

寄送郵件通知

```
# 寄送郵件通知
if email_content:
    msg = MIMEMultipart()
    msg['From'] = sender_email
    msg['To'] = receiver_email
    msg['Subject'] = '[Run Crawler] 元智大學'

    msg.attach(MIMEText(email_content, 'plain'))
```

透過 SMTP_SSL 發送郵件

```
try:
    with smtplib.SMTP_SSL('smtp.gmail.com', 465) as server:
        server.login(sender_email, password)
        server.sendmail(sender_email, receiver_email, msg.as_string())
        print('郵件已成功寄送')
except Exception as e:
    print(f"Error: 無法寄送郵件 - {e}")
```

GitHub workflow yaml 程式碼

```
name: Web Crawler and Email

# 設定工作流程排程
on:
  schedule:
    # 使用 cron 表排式設定每天早上 7 點鐘 (UTC 時間 - 所以使用 23:00)
    - cron: '0 23 * * *' # UTC 時間為 23:00 - 相當於台灣時間的 07:00
  workflow_dispatch: # 允許在 Github 上手動執行

jobs:
  run-crawler:
    runs-on: ubuntu-latest


    steps:
      - name: Checkout code
        uses: actions/checkout@v2

      # 設定 Python 環境
      - name: Set up Python
        uses: actions/setup-python@v2
        with:
          python-version: '3.11' # 指定 Python 版本

      - name: Install dependencies
        run: |
          python -m pip install --upgrade pip
          pip install -r requirements.txt

      - name: Run Python script
        env:
          # 設定環境變數 - 這些值來自 GitHub Secrets
          SENDER_EMAIL: ${ secrets.SENDER_EMAIL }
          RECEIVER_EMAIL: ${ secrets.RECEIVER_EMAIL }
          GMAIL_PASSWORD: ${ secrets.GMAIL_PASSWORD }
          GOOGLE_CREDENTIALS_JSON: ${ secrets.GOOGLE_CREDENTIALS_JSON }
          SPREADSHEET_ID: ${ secrets.SPREADSHEET_ID }
        run: |
          python yzu_web_crawler.py
```


完整程式碼及說明儲存在GitHub

A screenshot of a GitHub repository page for a project named "Yzu_Web_Crawler". The repository is public and owned by "sunnyliuaviation". It shows a list of files including ".github/workflows", "image", "README.md", "requirements.txt", and "yzu_web_crawler.py". The "README" file is selected, showing a section titled "研究動機" (Research Motivation) in Chinese. The right sidebar contains metadata such as "About", "Releases", "Packages", and "Languages", indicating the project is written in Python (100.0%).

Yzu_Web_Crawler Public

main 1 Branch 0 Tags

Go to file Add file Code

sunnyliuaviation Update README.md 52a6ab2 · 1 minute ago 17 Commits

.github/workflows	Update yzu_web_crawler.yml	2 weeks ago
image	Add files via upload	3 minutes ago
README.md	Update README.md	1 minute ago
requirements.txt	Update requirements.txt	2 weeks ago
yzu_web_crawler.py	Update yzu_web_crawler.py	2 weeks ago

README

研究動機

隨著訊息化時代的到來，網絡資訊的更新速度日益加快，學校及各行政單位的公告、通知和最新消息通常都會在官網上發佈。對於我身為學生而言，定期查閱這些最新的重要資訊是非常重要的。然而，由於資訊更新頻繁，若依賴手動查詢，不僅耗費大量時間與精力，也容易錯過關鍵的訊息，因此想製作一個網頁爬蟲來抓取最新消息。

About: No description, website, or topics provided.

Readme Activity 0 stars 1 watching 0 forks

Releases: No releases published. [Create a new release](#)

Packages: No packages published. [Publish your first package](#)

Languages: Python 100.0%

連結: https://github.com/sunnyliuaviation/Yzu_Web_Crawler

執行結果

儲存到Google Sheet

Yzu_Web_Crawler ☆ 📁 ☁			
檔案 編輯 查看 插入 格式 資料 工具 擴充功能 說明			
🔍 ↶ ↷ 🖨 🗑 100% NT\$ % .0 .00 123 預設 (... - 10 +			
F5	fx		
	A	B	C
1	Title	Link	Date
2	【轉知Announce	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1795-11	2024-12-05
3	【轉知Announce	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1794-11	2024-12-05
4	元智管院躋身全	https://www.yzu.edu.tw/admin/pr/index.php/tw/epaper-tw/8176-2	2024-12-05
5	元智大學首度參	https://www.yzu.edu.tw/admin/pr/index.php/tw/epaper-tw/8135-2	2024-11-21
6	[轉知] 新伊拉斯	https://www.yzu.edu.twhttps://gao.yzu.edu.tw/index.php/tw/news	2024-12-05
7	【免費課程資訊	https://www.yzu.edu.tw/admin/rd/index.php/tw/news-tw/7161-mig	2024-12-02
8	元智大學終身教	https://www.yzu.edu.tw/index.php/tw/news-tw/lifelong/335-lifelon	2024-10-18
9	終身教育部 ~ 好	https://www.yzu.edu.tw/index.php/tw/news-tw/lifelong/334-lifelon	2024-10-08
10	元智大學首度參	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/340-202411	2024-11-25
11	元智大學勇奪7金	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/339-202411	2024-11-25
12	元智大學勇奪20	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/343-202412	2024-12-05
13	元智大學資傳系	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/342-202412	2024-12-05
14	【轉知】教育部	https://www.yzu.edu.tw/admin/so/index.php/tw/news-tw/938-zhu	2024-12-09
15	【學務處法規公	https://www.yzu.edu.tw/admin/st/index.php/tw/news-tw/5678-rule	2024-12-10
16	轉知:「2025-202	https://www.yzu.edu.twhttps://gao.yzu.edu.tw/index.php/tw/news	2024-12-11
17	【法規修訂公告	https://www.yzu.edu.tw/admin/so/index.php/tw/news-tw/940-fa-g	2024-12-11
18	元智大學榮獲美	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/346-202412	2024-12-11
19	元智學子勇奪「2	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/345-202412	2024-12-11
20	【選課訊息】11	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1799-11	2024-12-12

成功收到郵件，且公告內容沒有重複

[Run Crawler] 元智大學 收件匣

寄給我

Title: 【諮就組公告】「2025 有備而來」元智大學企業校園徵才博覽會 開放報名中
Link: <https://www.yzu.edu.tw/admin/st/index.php/tw/news-tw/5719-2024-12-17>
Date: 2024-12-17

Title: 【公告Announcement】1131期末考試資訊&衝突考登記公告 / 2024 Fall Semester Final Exam Announcement & Exam Conflict Request
Link: <https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1432-final-exam>
Date: 2024-12-17

Title: 2024國際聖誕舞會
Link: <https://www.yzu.edu.twhttps://gao.yzu.edu.tw/index.php/tw/news-tw/2024guo-ji-sheng-dan-wu-hui-yzu-international-christmas-gala>
Date: 2024-12-17

Title: 【免費課程資訊】1131230國立成功大學學術誠信推動辦公室舉辦學術誠信系列講座：從生成式AI談資訊查核與學術文獻引用
Link: <https://www.yzu.edu.tw/admin/rd/index.php/tw/news-tw/7189-mian-fei-ke-cheng-zi-xun-1131230guo-li-cheng-gong-da-xue-xue-cheng-xin-ban-tui-dong-gong-shi-ju-ban-xue-shu-cheng-xin-xi-lie-jiang-zuo-cong-sheng-cheng-shi-lai-tan-zi-xun-cha-he-yu-xue-shu-wen-xian-yin-yong>
Date: 2024-12-17

[Run Crawler] 元智大學 收件匣

成功收到郵件

12月17日 週二 上午7:23 (1天前) ☆ ☺ ↶ ⋮

Title: 【學務處法規公告】本校「學生會組織章程」條文修正備查
Link: <https://www.yzu.edu.tw/admin/st/index.php/tw/news-tw/5713-rule1131216-1>
Date: 2024-12-16

遇到的困難及如何解決

1. 由於這次不單單只有做爬蟲，也要將抓取下來的公告透過 Gmail 寄送，還有將資料儲存到 Google Sheet 的部分，需要用到 API 串接，因此複雜度上升。於是我先將這個專案分成三個部份來製作，分別是網頁爬蟲、寄送郵件以及儲存資料並進行比對，等到三個部分都學會後，再將三個部分程式碼融合在一起，這樣對我來說學習起來相對容易。
2. 在製作這個爬蟲時，經常遇到報錯，且如果單從 Google 上找尋資料，也較難將錯誤完全排除，且身邊也沒有擁有相關知識背景的人能詢問。因此，我透過 ChatGPT 的協助，來幫助我除錯，同時，自己也進行不斷的摸索。

待解決的問題

在公告儲存時，有些連結並沒有轉成超連結，如下圖：

Yzu_Web_Crawler ☆ 📁 ☁

檔案 編輯 查看 插入 格式 資料 工具 擴充功能 說明

🔍 ↶ ↷ 🖨 🗑 100% ▾ NT\$ % .0 .00 123 預設 (... ▾ - 10 +

F5

	A	B	C
1	Title	Link	Date
2	【轉知Announce	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1795-11	2024-12-05
3	【轉知Announce	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1794-11	2024-12-05
4	元智管院踴身全	https://www.yzu.edu.tw/admin/pr/index.php/tw/epaper-tw/8176-2	2024-12-05
5	元智大學首度參	https://www.yzu.edu.tw/admin/pr/index.php/tw/epaper-tw/8135-2	2024-11-21
6	[轉知] 新伊拉斯	https://www.yzu.edu.twhttps://gao.yzu.edu.tw/index.php/tw/news-2	2024-12-05
7	【免費課程資訊	https://www.yzu.edu.tw/admin/rd/index.php/tw/news-tw/7161-mis	2024-12-02
8	元智大學終身教	https://www.yzu.edu.tw/index.php/tw/news-tw/lifelong/335-lifelon	2024-10-18
9	終身教育部～好	https://www.yzu.edu.tw/index.php/tw/news-tw/lifelong/334-lifelon	2024-10-08
10	元智大學首度參	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/340-202411	2024-11-25
11	元智大學勇奪7金	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/339-202411	2024-11-25
12	元智大學勇奪20	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/343-202412	2024-12-05
13	元智大學資傳系	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/342-202412	2024-12-05
14	【轉知】教育部	https://www.yzu.edu.tw/admin/so/index.php/tw/news-tw/938-zhu	2024-12-09
15	【學務處法規公	https://www.yzu.edu.tw/admin/st/index.php/tw/news-tw/5678-rule	2024-12-10
16	轉知:「2025-20	https://www.yzu.edu.twhttps://gao.yzu.edu.tw/index.php/tw/news-2	2024-12-11
17	【法規修訂公告	https://www.yzu.edu.tw/admin/so/index.php/tw/news-tw/940-fa-g	2024-12-11
18	元智大學榮獲美	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/346-202412	2024-12-11
19	元智學子勇奪「	https://www.yzu.edu.tw/index.php/tw/news-tw/honor/345-202412	2024-12-11
20	【選課訊息】11	https://www.yzu.edu.tw/admin/aa/index.php/tw/news-tw/1799-11	2024-12-12

學習心得

原本就對製作 Python 網頁爬蟲感興趣的我，透過這次製作爬蟲的經驗，我學到了如何將網頁爬蟲技術、Google Sheets API 以及 Gmail SMTP 整合起來，實現一個自動化的資訊抓取與通知系統。

我認為，將專案分為爬取網頁、寄送郵件、儲存資料三個部分進行，是一個有效的學習策略，讓我能逐步掌握每一個技術環節，最終成功地完成了整合，我也發現網路的資源非常龐大，透過自己摸索、查詢資料的過程，使我累積經驗，知道如何掌握查詢想要資訊的關鍵字，找到我需要的資源與資訊。過程中，雖然遇到了許多挑戰，如 API 串接、錯誤處理等，但在 ChatGPT 的協助下，我順利排除各種錯誤，最後總共花了約三個月的時間，完成這個專案。

改善及建議

1. **資料儲存與查詢優化:** 目前的資料儲存在 Google Sheet 上，這對於小規模的資料管理是有效的。但如果公告數量增加，Google Sheet 的查詢效率可能會下降。**日後考慮使用**如 Firebase、**SQL** 等更強大的**資料庫進行儲存**，以便能有效管理大量數據。
2. **公告過濾與分類:** 除了目前的爬取公告功能，未來可以**加入公告的過濾或分類功能**，**根據不同的關鍵字、類別來進行篩選**。例如，根據公告的標題或內容篩選出學術、課程相關或校內活動等特定類別，可以更快速得到需要的資訊。

參考資料

- [【 Python 爬蟲 】 2 小時初學者課程 ：一次學會 PTT 爬蟲、Hahow 爬蟲、Yahoo 電影爬蟲！](#)
- [【python】selenium 網頁自動化、網路爬蟲 | 爬蟲 | python 爬蟲 | 自動化 | pycharm |](#)
- [Python Email 發送電子郵件 - 基本教學 By 彭彭](#)
- [GitHub Action YAML 撰寫技巧 - 環境變數\(Environment Variables\) 與 秘密 \(Secrets\)](#)
- 爬蟲資料擷取自 [元智大學](#) 官網